260407 数据库 SKILL 整理

交付目标

要解决什么问题?

- 核心：数据源越来越多、越来越复杂，如何进行整理、组织，让模型使用更好?
- 数据源接入之后，模型需要知道这个数据源的内容、使用方式（最佳实践）、何时使用（在什么场景下）
- 链接任务与context，这是一个双向index
  - 给定任务，我需要查哪些数据源、以什么顺序来完成
  - 给定数据源，能服务哪些任务
- 与人的对齐与交互
  - 引入人的偏好与先验信息：什么场景下偏好哪一些数据源
  - 把skill以可视化形式呈现出来，并且展示skill之间的graph（基于index）

intro

从一个数据库的基本schema出发，完善各个column、各个table的含义、描述、潜在场景，最终产出目标格式的claude skill md文件。每一个table对应于一个skill md。

数据文件示例

原始 table schema data（敏感已删除）

数据（敏感已删除）

生成描述（敏感已删除）

产出skill md 示例

SKILL.md
3.57KB

NL2SQL SKILL 创建工具代码：

creat_skills.zip
11.32KB

NL2SQL Skill 创建工具

本目录包含用于自动生成 NL2SQL Agent 技能文件的完整工具链。通过从数据库采样、智能生成表描述，最终输出标准化的技能文档。

概述

Skill 是 NL2SQL Agent 的核心组件，为 Agent 提供数据库表的详细知识，包括：

- 表结构和字段定义
- 业务语义和使用场景
- 示例数据
- 查询指导

本工具链通过三个步骤自动完成 Skill 创建：

1. 数据采样 - 从数据库提取示例数据
2. 智能描述生成 - 使用 LLM 生成表和列的详细描述
3. Skill 格式化 - 输出标准化的技能文件

工具组件

1. enrich_schema_with_examples.py

用途: 从 PostgreSQL 数据库采样，为每个列添加示例数据

功能:

- 连接数据库并采样非空数据
- 为每个列添加 `example` 字段
- 输出带示例的增强版 schema 文件

用法:

cd create_skills

python enrich_schema_with_examples.py

配置:

- 默认采样数量: 10 条/列
- 输入文件: `db/chj_db_schema_clean.json`
- 输出文件: `db/chj_db_schema_with_examples.json`

环境要求:

.env 文件需要包含以下配置:

DB_NAME=context_server

DB_USER=your_username

DB_HOST=your_host

DB_PORT=5432

DB_PASSWORD=your_password

2. db_description_agent.py

用途: 使用 LLM 为每个表生成详细的自然语言描述

功能:

- 读取带示例的 schema 文件
- 调用 LLM 分析表结构和业务含义
- 生成表概述、使用场景、列描述
- 支持多线程并行处理
- 输出 JSON 和 Markdown 格式

用法:

基本用法

python db_description_agent.py

自定义参数

python db_description_agent.py \

  --schema db/chj_db_schema_with_examples.json \

  --output db/descriptions \

  --format both \

--workers 5 \

--limit 10

参数说明:

- `--schema`: 输入 schema 文件路径
- `--output`: 输出目录
- `--format`: 输出格式 (`json`, `markdown`, `both`)
- `--workers`: 并行工作线程数
- `--limit`: 限制处理的表数量（用于测试）

输出文件:

- `table_descriptions.json` - 所有表的 JSON 描述
- `table_descriptions.md` - 人类可读的 Markdown 文档
- `tables/<table_name>.json` - 单个表的详细描述

环境要求:

.env 文件需要包含:

OPENAI_API_KEY=your_api_key

OPENAI_BASE_URL=your_base_url

OPENAI_MODEL=gpt-5

3. table_description_json_to_skills.py

用途: 将表描述转换为标准 Skill 文件

功能:

- 读取 `table_descriptions.json`
- 为每个表生成 `SKILL.md` 文件
- 包含表结构、字段说明、使用场景
- 输出标准化的技能目录结构

用法:

python table_description_json_to_skills.py

配置:

- 输入文件: `table_descriptions.json`
- 输出目录: `skills_table_70/`

- 每个表一个目录，包含 `SKILL.md`

输出结构:

```
skills_table_70/
├── table1/
│   └── SKILL.md
├── table2/
│   └── SKILL.md
└── ...
```

完整工作流程

步骤 1: 准备环境

cd create_skills

安装依赖

pip install psycopg2-binary python-dotenv openai tqdm

配置环境变量

cp .env.example .env

编辑 .env 文件，填入数据库和 LLM 配置

步骤 2: 数据采样

从数据库采样示例数据

python enrich_schema_with_examples.py

检查输出

ls -lh db/chj_db_schema_with_examples.json

步骤 3: 生成表描述

使用 LLM 生成表描述

```
python db_description_agent.py \
  --schema db/chj_db_schema_with_examples.json \
  --output db/descriptions \
  --format both \
  --workers 3
```

查看结果

ls db/descriptions/

步骤 4: 生成 Skill 文件

转换为 Skill 格式

python table_description_json_to_skills.py

检查生成的技能

ls skills_table_70/

步骤 5: 使用技能

将技能文件复制到 Agent 的技能目录

cp -r skills_table_70/* ../../skills/

或在 Agent 配置中引用# 编辑 nl2sql_agent.yaml，添加技能路径

实现细节

数据流

```
原始 Schema (chj_db_schema_clean.json)
    ↓
[enrich_schema_with_examples.py]
    ↓ 添加 example 字段
增强 Schema (chj_db_schema_with_examples.json)
    ↓
[db_description_agent.py]
    ↓ LLM 分析
表描述 (table_descriptions.json)
    ↓
[table_description_json_to_skills.py]
    ↓ 格式化
Skill 文件 (SKILL.md)
```

关键特性

智能采样:

- 自动跳过空值和空字符串
- 使用 DISTINCT 避免重复
- 限制采样数量以控制文件大小

LLM 优化:

- 结构化 prompt 确保输出一致性
- 多线程并行处理提高效率
- JSON 解析容错处理

Skill 标准化:

- 符合 NL2SQL Agent 技能格式
- 包含完整的表结构 DDL
- 业务友好的描述语言

故障排查

数据库连接失败

测试数据库连接

python -c "import psycopg2; conn = psycopg2.connect(dbname='context_server'); print('OK')"# 检查环境变量echo $DB_NAME $DB_HOST $DB_PORT

LLM 调用失败

测试 OpenAI API

python -c "from openai import OpenAI; client = OpenAI(); print(client.models.list())"# 检查 API 配额和网络连接

输出文件缺失

检查文件路径

ls -la db/

ls -la db/descriptions/

检查权限

chmod +x *.py

最佳实践

1. 增量更新: 修改单个表时，使用 `--limit 1` 参数测试
2. 并发控制: 根据 API 限制调整 `--workers` 数量
3. 版本控制: 将生成的技能文件纳入 Git 管理
4. 质量检查: 定期审查生成的描述，优化 prompt

扩展开发

添加新的输出格式

修改 `table_description_json_to_skills.py`，添加新的格式化函数

自定义 Prompt

编辑 `db_description_agent.py` 中的 `TABLE_DESCRIPTION_PROMPT`

支持其他数据库

修改 `enrich_schema_with_examples.py` 的连接逻辑